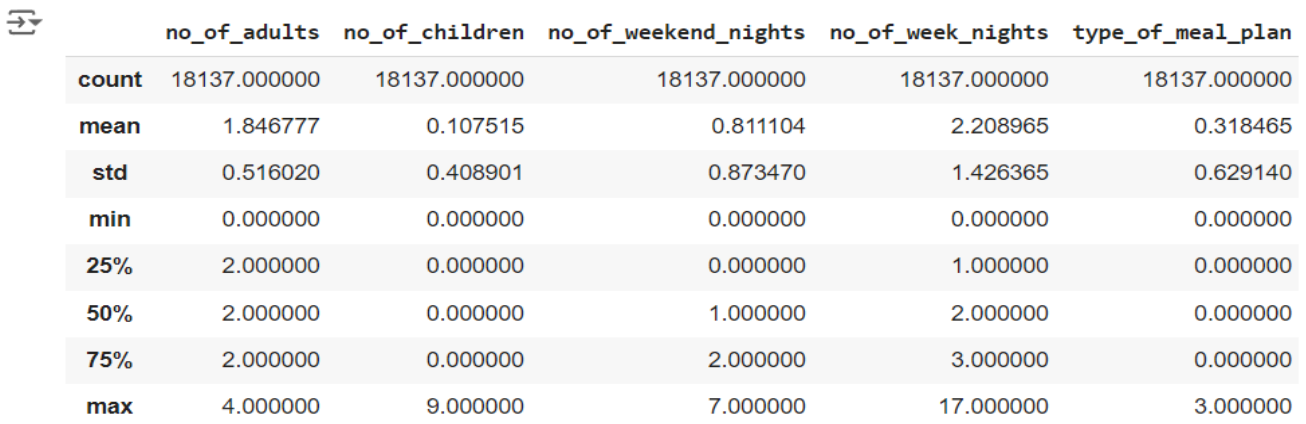


Data Collection and Preprocessing Phase

Date	24 April 2024
Team ID	740663
Project Title	RESERVATION CANCELLATION PREDICTION
Maximum Marks	6 Marks

Data Exploration and Preprocessing Template

Identifies data sources, assesses quality issues like missing values and duplicates, and implements resolution plans to ensure accurate and reliable analysis.

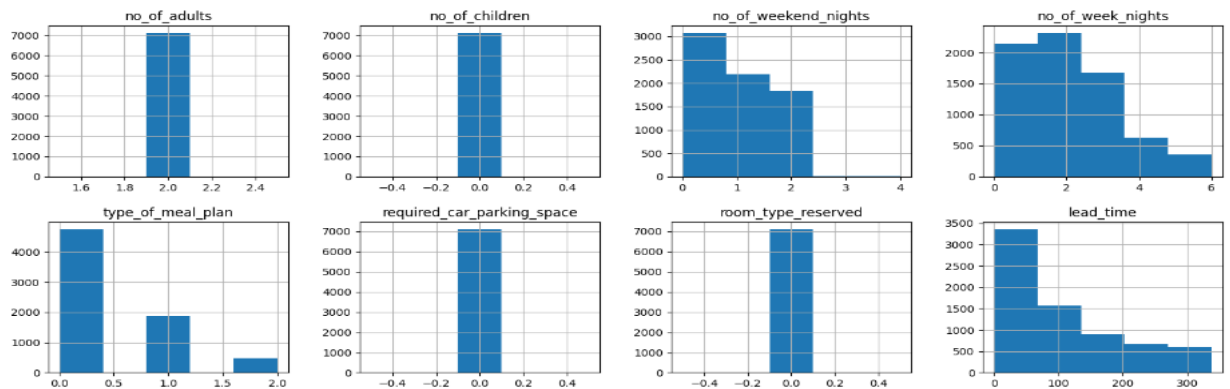
Section	Description
Data Overview	<pre>[] train_data.describe()</pre>
	

```
[ ] test_data.describe()
```

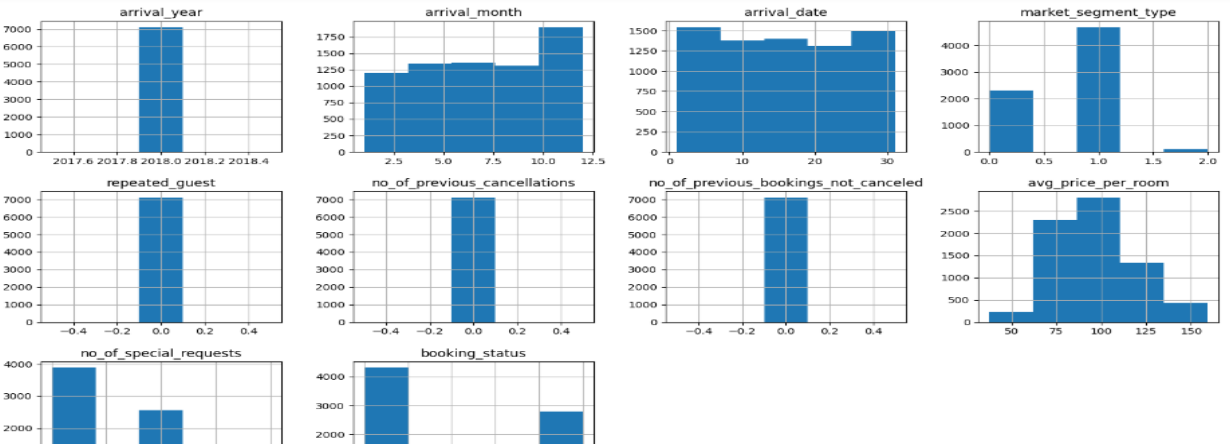


	no_of_adults	no_of_children	no_of_weekend_nights	no_of_week_nights	type_of_meal_plan
count	18138.000000	18138.000000	18138.000000	18138.000000	18138.000000
mean	1.843147	0.103043	0.810343	2.199636	0.329639
std	0.521403	0.396295	0.867833	1.395298	0.639016
min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	2.000000	0.000000	0.000000	1.000000	0.000000
50%	2.000000	0.000000	1.000000	2.000000	0.000000
75%	2.000000	0.000000	2.000000	3.000000	0.000000
max	4.000000	10.000000	6.000000	16.000000	3.000000

```
[ ] filtered_data.hist(bins=5, figsize=(18, 18))
plt.show()
```




```
[ ]
```




Univariate
Analysis

Bivariate Analysis

```
countplot_of_z(x='no_of_children', hue='booking_status', title='No of Children vs Booking Status')
```



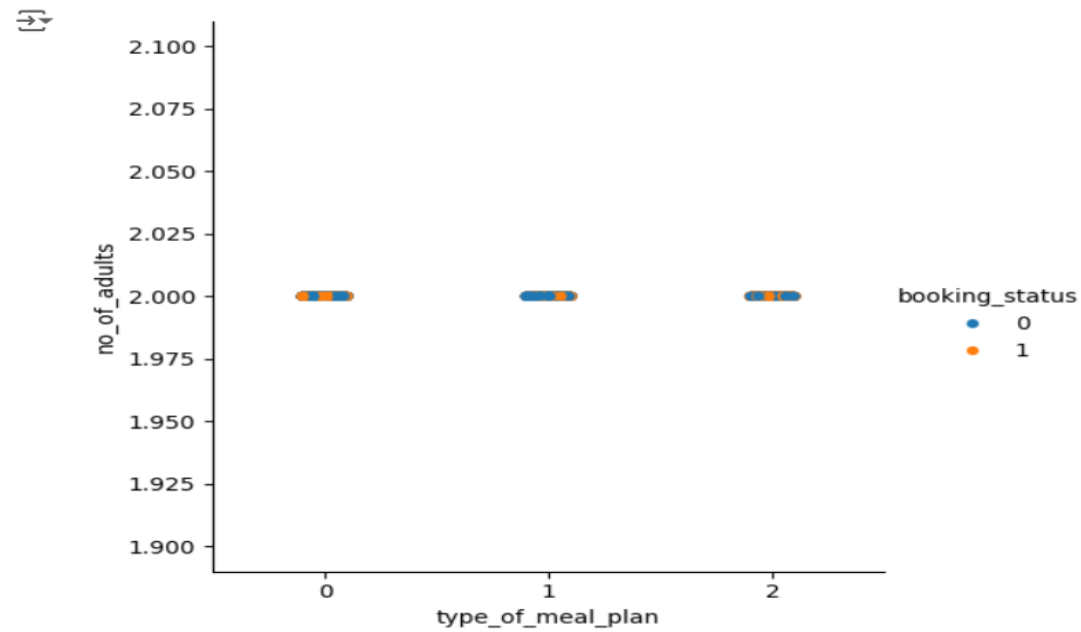
```
[ ] sns.scatterplot(data=filtered_data, x='type_of_meal_plan', y='booking_status',)
plt.show()
```




Multivariate Analysis

	no_of_adults	no_of_children	no_of_weekend_nights	no_of_week_nights	type_of_meal_plan	required_car_parking_space	room_type_reserved	lead_time	arrival_year	arrival_month	arrival_date	market_segment_type	repeated_guest	no_of_previous_cancellations	no_of_previous_bookings_not_canceled	avg_price_per_room	no_of_special_requests	booking_status
no_of_adults	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
no_of_children	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
no_of_weekend_nights	nan	nan	1.000000	0.002152	-0.048610	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
no_of_week_nights	nan	nan	0.002152	1.000000	-0.108686	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
type_of_meal_plan	nan	nan	-0.048610	-0.108686	1.000000	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
required_car_parking_space	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
room_type_reserved	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
lead_time	nan	nan	0.013533	0.189781	0.019528	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
arrival_year	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
arrival_month	nan	nan	0.008513	0.082517	-0.024910	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
arrival_date	nan	nan	0.053746	-0.006413	0.054452	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
market_segment_type	nan	nan	0.037351	-0.031379	0.055280	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
repeated_guest	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
no_of_previous_cancellations	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
no_of_previous_bookings_not_canceled	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
avg_price_per_room	nan	nan	-0.125499	-0.112414	0.148880	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
no_of_special_requests	nan	nan	0.051803	0.013128	0.063569	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan
booking_status	nan	nan	-0.055431	0.026674	0.112614	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan	nan

```
[ ] sns.catplot(x='type_of_meal_plan', y='no_of_adults', hue='booking_status', data=filtered_data)
plt.show()
```



Outliers



Data Preprocessing Code Screenshots

Loading Data

```
#reading the test data
test_data=pd.read_csv('/content/test__dataset.csv')
#reading the train data
train_data=pd.read_csv('/content/train__dataset.csv')
```

```
[ ] test_data.head()
```

	no_of_adults	no_of_children	no_of_weekend_nights	no_of_week_nights	type_of_meal_plan	rec
0	2	0	1	2	0	
1	2	0	0	2	0	
2	1	0	2	3	0	
3	2	0	2	0	2	
4	2	0	1	4	0	

```
[ ] train_data.head()
```

	no_of_adults	no_of_children	no_of_weekend_nights	no_of_week_nights	type_of_meal_plan	rec
0	2	0	1	4	0	
1	2	1	0	2	0	
2	1	0	1	5	0	
3	1	0	2	4	0	
4	2	0	0	4	1	

Handling
Missing
values

```
[ ] test_data.isna().sum()
```

```
no_of_adults      0
no_of_children    0
no_of_weekend_nights  0
no_of_week_nights  0
type_of_meal_plan  0
required_car_parking_space  0
room_type_reserved  0
lead_time         0
arrival_year      0
arrival_month     0
arrival_date      0
market_segment_type  0
repeated_guest    0
no_of_previous_cancellations  0
no_of_previous_bookings_not_canceled  0
avg_price_per_room  0
no_of_special_requests  0
dtype: int64
```

```
[ ] train_data.isna().sum()
```

```
no_of_adults      0
no_of_children    0
no_of_weekend_nights  0
no_of_week_nights  0
type_of_meal_plan  0
required_car_parking_space  0
room_type_reserved  0
lead_time         0
arrival_year      0
arrival_month     0
arrival_date      0
market_segment_type  0
repeated_guest    0
no_of_previous_cancellations  0
no_of_previous_bookings_not_canceled  0
avg_price_per_room  0
no_of_special_requests  0
booking_status    0
dtype: int64
```

Save
Processed
Data

```
[ ] import joblib # Import the pickle m  
    joblib.dump(model, 'model.pkl')
```

⇒ ['model.pkl']